

# Algorytmy ewolucyjne. Zadanie 2

Michał Dettlaff, Dariusz Kuziemski

17 stycznia 2010

## 1 Wprowadzenie

Celem rozpatrywanego problemu jest porównanie skuteczności strategii ewolucyjnej i algorytmu genetycznego w wybranych problemach optymalizacji numerycznej.

Funkcjami, z których skorzystamy w eksperymencie - funkcje ciągłe, potencjalnie trudne do optymalizacji - będą uogólniona Funkcja Rosenbrocka oraz uogólniona Funkcja Griewanka.

Dotychczas problemami optymalizacji za pomocą strategii ewolucyjnych zajmowali się m.in. Pedro A. F. Cruz oraz Delfim F. M. Torres w swojej pracy *Evolution strategies in optimization problems*.

## 2 Metodologia

By porównać skuteczność strategii ewolucyjnej i algorytmu genetycznego wykorzystamy **Cumulative Step Size Adaptation (CSA)** (Kumulowana długość kroku) jako przykład strategii oraz **Differential Evolution** (Ewolucja przyrostowa) jako algorytm genetyczny.


Strategie ewolucyjne zostały pomyślane jako narzędzie optymalizacji parametrycznej. Rozwiązania mają tu postać m-wymiarowych wektorów o współrzędnych rzeczywistych. Charakterystyczną cechą tej metaheurystyki jest samoadaptacja parametrów sterujących, które podlegają ewolucji wraz z właściwymi rozwiązaniami. Osiąga się to przez rozszerzenie reprezentacji osobnika, dołączając do wektora rozwiązania wektor parametrów sterujących.

Algorytmy genetyczne są rodzajem algorytmów przeszukujących przestrzeń alternatywnych rozwiązań problemu w celu wyszukania rozwiązań najlepszych. Ich charakterystyczną cechą jest binarne kodowanie rozwiązania jako pojedynczego chromosomu. Selekcja wstępna jest realizowana za

pomocą mechanizmu selekcji proporcjonalnej (algorytm wymaga więc niekiedy odpowiedniego przekształcenia funkcji oceny). Wytwarzanie osobników potomnych jest realizowane przy użyciu krzyżowania prostego oraz następującej po nim mutacji równoległej, przy czym krzyżowanie jest uważane za mechanizm podstawowy. W algorytmie stosuje się pełną wymianę pokoleń, tak więc w każdym cyklu wytwarza się tylu osobników potomnych, ile wynosi wielkość populacji. Wyróżnia się trzy zasadnicze grupy zastosowań AG: algorytmy przeszukujące (Search), optymalizujące (Optimization) i uczące (Learning). Wymienione grupy nie są jednak rozłączne i granica między nimi jest płynna.


Pierwsza wykorzystana funkcja testowa - funkcja Rosenbrock'a - jest funkcją niewypukłą używaną w optymalizacji jako test dla algorytmów optymalizacji. Zwana jest też ze względu na swój kształt "Doliną Rosenbrocka" lub "Funkcją Banana Rosenbrocka". Funkcja ta jest popularnie używana do przedstawiania zachowań algorytmów optymalizacji.

$$f(x) = \sum_{i=1}^{n-1} [100(x_{i+1} - x_i)^2 + (x_i - 1)^2]$$



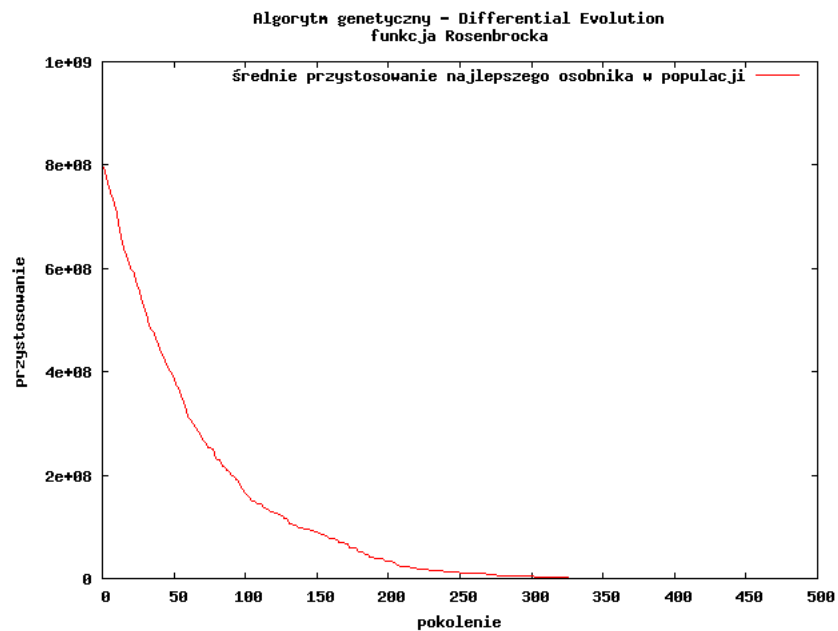
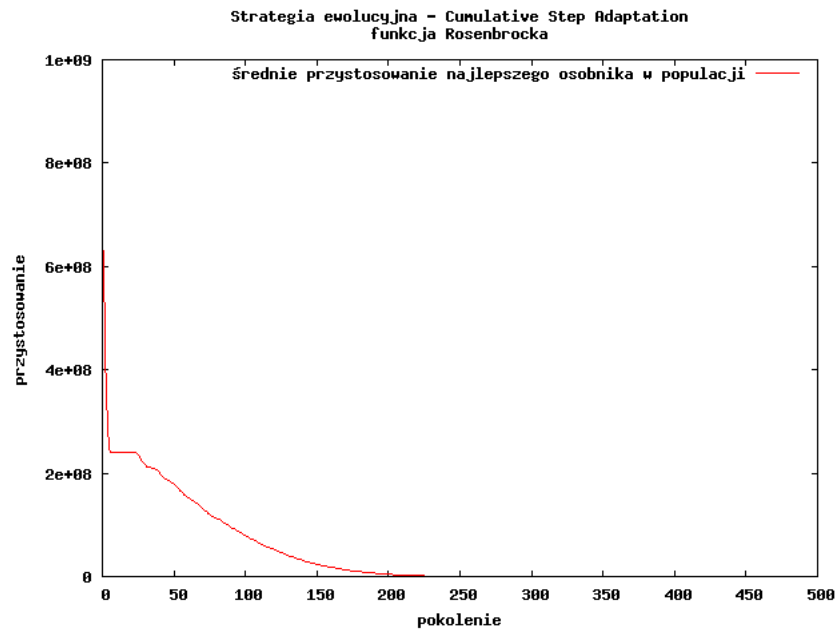
Drugą funkcją jest Funkcja Griewanka, która funkcją trudną do optymalizacji z powodu silnej zależności wewnętrznej pomiędzy zmiennymi. Uogólnioną, n-wymiarową funkcję Griewanka definiuje się następującym wzorem:

$$f(x) = \frac{1}{4000} \sum_{i=1}^n x_i^2 - \prod_{i=1}^n \cos(x_i/\sqrt{i}) + 1$$



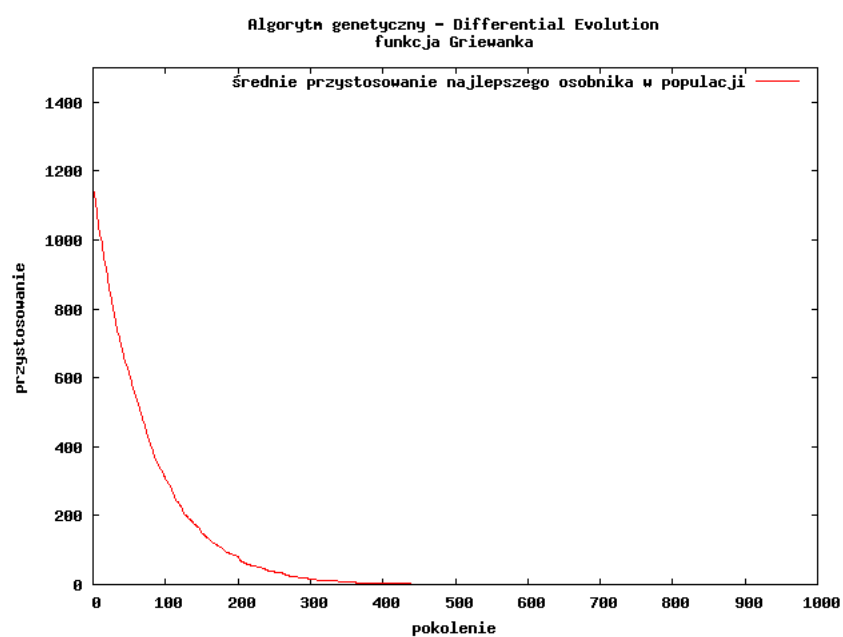
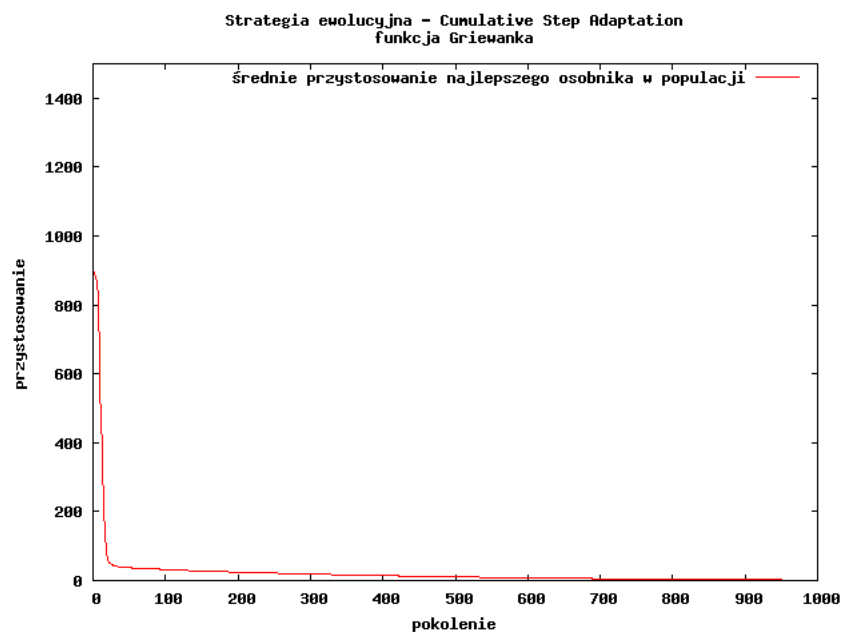
### 3 Wyniki

Funkcja Rosenbrocka



Dla funkcji Rosenbrocka strategia ewolucyjna (tj. Kumulowana długość kroku) okazuje się skuteczniejsza od algorytmu genetycznego (tj. Ewolucji przyrostowej) - tzn. szybciej znajduje rozwiązanie zadanego problemu optymalizacji. Warto jednak zauważyć, że współczynnik zmiany średniego najlepszego osobnika w populacji zmienia się nierównomiernie - najbardziej widoczne efekty uzyskujemy dla pierwszych pokoleń. Natomiast współczynnik dla algorytmu genetycznego równomiernie dąży do rozwiązania.

## Funkcja Griewanka



W przypadku funkcji Griewanka szybsze rozwiązanie zagadnienia otrzymujemy z wykorzystaniem algorytmu genetycznego. Jednak zauważamy idee podobne jak dla funkcji Rosenbrocka - zastosowana strategia ewolucyjna zwraca lepsze wyniki dla pokoleń początkowych, podczas gdy algorytm genetyczny pracuje jednostajnie.

Otrzymane wyniki porównań dla testowanych funkcji skłaniają do następującego wniosku: najbardziej efektywne rozwiązania zadań optymalizacji możemy uzyskać stosując dla pierwszych pokoleń strategię ewolucyjną, a następnie algorytm genetyczny.

## 4 Bibliografia

Kwaśnicka H.: *Obliczenia ewolucyjne w sztucznej inteligencji*.

Oficyna Wydawnicza Politechniki Wrocławskiej, Wrocław, 1999.

[http://prawo.uni.wroc.pl/~kwasnicki/todownload/prognozowanie\\_popytu.pdf](http://prawo.uni.wroc.pl/~kwasnicki/todownload/prognozowanie_popytu.pdf)

[http://www.kirj.ee/public/Phys\\_Math/2007/issue\\_4/phys-2007-4-3.pdf](http://www.kirj.ee/public/Phys_Math/2007/issue_4/phys-2007-4-3.pdf)

[http://stefanbrock.neostrada.pl/materialy/NMS/CI\\_wyklad\\_ewoluc\\_2.pdf](http://stefanbrock.neostrada.pl/materialy/NMS/CI_wyklad_ewoluc_2.pdf)

<http://www.mimuw.edu.pl/~grygiel/archive/dokumenty/notatki.pdf>

[http://pl.wikipedia.org/wiki/Funkcja\\_Rosenbrock'a](http://pl.wikipedia.org/wiki/Funkcja_Rosenbrock'a)